

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA
PAULA SOUZA

Faculdade de Tecnologia Baixada Santista Rubens Lara
Curso Superior de Tecnologia em Análise e
Desenvolvimento de Sistemas

GUILHERME GONZAGA COELHO KROHLING
GIOVANNA DA SILVA MELO
NICKOLAS LIMA GOMES

PORTOGPT

Leitura, organização e busca automatizada de documentos

Santos, SP

2026

GUILHERME GONZAGA COELHO KROHLING

GIOVANNA DA SILVA MELO

NICKOLAS LIMA GOMES

PORTOGPT

Leitura, organização e busca automatizada de documentos

Trabalho de Conclusão de Curso
apresentado à Faculdade de Teconologia
Rubens Lara, como exigência para a
obtenção do Título de Tecnólogo em Análise
e Desenvolvimento de Sistemas.

Orientador: Professor Alexandre Garcia de
Oliveira

Santos, SP

2026

RESUMO

O presente trabalho aborda o desenvolvimento do PortoGPT, um assistente virtual inteligente baseado em Inteligência Artificial, concebido para otimizar a gestão, criação e recuperação de documentos institucionais. A dificuldade na localização ágil de informações resulta em perda de produtividade, bem como a falta de padronização na criação de novos documentos. Para solucionar estes desafios, o projeto utiliza a arquitetura RAG (Retrieval-Augmented Generation) combinada com Grandes Modelos de Linguagem (LLMs). O sistema permite o carregamento de arquivos PDF com extração automática de metadados e validação humana (Human-in-the-loop). Além disso, introduz um motor de renderização (Jinja) que transforma dados brutos fornecidos pelo usuário em variáveis inteligentes, gerando automaticamente novos PDFs padronizados (com cabeçalho, rodapé e logotipos). A solução, implementada com Python, FastAPI, LlamaIndex, Groq AI e SQLite, visa mitigar alucinações da IA e fornecer interações baseadas exclusivamente na base documental da organização.

Palavras-chave: Inteligência Artificial. RAG. Jinja. Gestão Documental. Assistente Virtual.

ABSTRACT

This study addresses the development of PortoGPT, an intelligent virtual assistant based on Artificial Intelligence, designed to optimize the management, creation, and retrieval of institutional documents. The difficulty in quickly locating information results in lost productivity, as does the lack of standardization in creating new documents. To solve these challenges, the project utilizes the RAG (Retrieval-Augmented Generation) architecture combined with Large Language Models (LLMs). The system allows for PDF uploads with automatic metadata extraction and human-in-the-loop validation. Furthermore, it introduces a rendering engine (Jinja) that transforms raw data provided by the user into smart variables, automatically generating new standardized PDFs (with headers, footers, and logos). The solution, implemented with Python, FastAPI, LlamaIndex, Groq AI and SQLite, aims to mitigate AI hallucinations and provide interactions based exclusively on the organization's documentary base.

Keywords: Artificial Intelligence. RAG. Jinja. Document Management. Virtual Assistant.

LISTA DE ABREVIATURAS E SIGLAS

API	Application Programming Interface - 26
GPT	Generative Pre-trained Transformer - 10
HTML	HyperText Markup Language
IA	Inteligência Artificial - 9
JSON	JavaScript Object Notation
LLM	Large Language Model - 9
LLaMA	Large Language Model
MER	Modelo Entidade-Relacionamento - 21
NLP	Natural Language Processing - 10
PDF	Portable Document Format - 11
RAG	Retrieval-Augmented Generation - 10
RF	Requisito Funcional - 27
RN	Regra de Negócio - 29
RNF	Requisito Não Funcional - 28
ROI	Return on Investment - 29
SSO	Single Sign-On - 55
TI	Tecnologia da Informação - 9

LISTA DE FIGURAS

Figura 1 – Interseção dos modelos LLM no ecossistema de Inteligência Artificial.....	9
Figura 2 – Fluxo de Funcionamento da arquitetura RAG.....	11
Figura 3 – Visão geral do funcionamento do PortoGPT com RAG.....	12
Figura 4 – Diagrama de Caso de Uso.....	16
Figura 5 – Diagrama de Atividades (Usuário Comum).....	18
Figura 6 – Diagrama de Atividades (Administrador).....	20
Figura 7 - Diagrama de Banco de Dados.....	23
Figura 8 – Tela de Protótipo.....	24
Figura 9 – Tela de Login.....	43
Figura 10 – Tela Inicial (Chat).....	44
Figura 11 – Histórico e Busca de Chats.....	45
Figura 12– Detalhes do Usuário.....	46
Figura 13 – Meu perfil.....	47
Figura 14 – PDFs disponíveis.....	48
Figura 15 – Minhas solicitações.....	49
Figura 16 – Minhas notificações.....	50
Figura 17 – Administração.....	50
Figura 18 – Usuários.....	51
Figura 19 – Conhecimento da IA.....	52
Figura 20 – Gerenciamento de PDFs.....	53
Figura 21 – Solicitações de documentos.....	54
Figura 22 - Templates.....	55

LISTA DE QUADROS

Quadro 1 – Caso de Uso Estendido: Fazer Login.....	29
Quadro 2 – Caso de Uso Estendido - Interagir com o Assistente (Chat).....	30
Quadro 3 – Caso de Uso Estendido: Utilizar Sugestões do Carrossel.....	31
Quadro 4 – Caso de Uso Estendido: Visualizar Histórico de Chats.....	31
Quadro 5 – Caso de Uso Estendido: Buscar Chats.....	32
Quadro 6 – Caso de Uso Estendido: Excluir Chat.....	32
Quadro 7 – Caso de Uso Estendido: Enviar PDF pelo Chat.....	33
Quadro 8 – Caso de Uso Estendido: Visualizar PDFs Disponíveis.....	34
Quadro 9 – Caso de Uso Estendido: Acompanhar Minhas Solicitações.....	34
Quadro 10 – Caso de Uso Estendido: Reenviar Solicitação Reprovada.....	35
Quadro 11 – Caso de Uso Estendido: Visualizar Notificações.....	36
Quadro 12 – Caso de Uso Estendido: Gerenciar PDFs.....	36
Quadro 13 – Caso de Uso Estendido: Reindexar Base Vetorial.....	37
Quadro 14 – Caso de Uso Estendido: Aprovar ou Reprovar Solicitação.....	37
Quadro 15 – Caso de Uso Estendido: Gerenciar Usuários.....	38
Quadro 16 – Caso de Uso Estendido: Configurar Parâmetros da IA.....	39
Quadro 17 – Caso de Uso Estendido: Gerenciar Templates.....	39
Quadro 18 – Caso de Uso Estendido: Gerar Documento por Template.....	40
Quadro 19 – Caso de Uso Estendido: Visualizar Dashboard Administrativo.....	41
Quadro 20 – Caso de Uso Estendido: Visualizar Perfil.....	41
Quadro 21 – Caso de Uso Estendido: Fazer Logout.....	42

LISTA DE TABELAS

Tabela 1 – Requisitos Funcionais do Sistema.....	27
Tabela 2 – Requisitos Funcionais do Sistema (Administrador).....	28
Tabela 3 – Requisitos Não Funcionais do Sistema (Geral).....	28
Tabela 4 – Requisitos de Negócios do Sistema.....	29


SUMÁRIO

1 INTRODUÇÃO.....	9
1.1 OBJETIVOS.....	13
1.2 OBJETIVOS ESPECÍFICOS.....	13
2 DESENVOLVIMENTO.....	14
2.1 CARACTERIZAÇÃO DA PESQUISA.....	14
2.2 MODELO DE NEGÓCIO.....	14
2.3 ELICITAÇÃO DE REQUISITOS.....	15
2.3.1 REQUISITOS DE USUÁRIOS.....	15
2.3.2 REQUISITOS DO SISTEMA.....	15
2.3.3 DIAGRAMA DE CASO DE USO.....	15
2.3.4 DIAGRAMA DE ATIVIDADES.....	17
2.3.5 DIAGRAMA DE BANCO DE DADOS.....	21
2.4 PROTOTIPAÇÃO.....	24
2.5 VALIDAÇÃO DE REQUISITOS.....	24
2.6 IMPLEMENTAÇÃO E HOMOLOGAÇÃO.....	24
2.7 DESENVOLVIMENTO DE SOFTWARE.....	25
2.7.1 FERRAMENTAS DE APOIO AO DESENVOLVIMENTO.....	25
2.7.2 DESENVOLVIMENTO FRONT-END.....	25
2.7.3 DESENVOLVIMENTO BACK-END.....	26
2.8 REQUISITOS.....	27
3 RESULTADO.....	42
3.1 TRABALHOS FUTUROS.....	55
4 CONCLUSÃO.....	57
5 REFERÊNCIAS.....	59

1 INTRODUÇÃO

A Inteligência Artificial (IA) tem desempenhado um papel cada vez mais relevante no ambiente corporativo, especialmente na rotina dos profissionais de Tecnologia da Informação (TI) (RUSSELL; NORVIG, 2013). O avanço de soluções baseadas em IA tem permitido a automação de processos, a otimização do acesso a informações e o suporte à tomada de decisão em diversas organizações. Atualmente, modelos de linguagem natural, como as *Large Language Models* (LLMs), representam uma das principais inovações nesse campo, possibilitando interações mais inteligentes e humanizadas entre sistemas e usuários (ZHAO et al., 2023).

Figura 1 – Interseção dos modelos LLM no ecossistema de Inteligência Artificial



Fonte: Neves, 2025.

O presente estudo teve sua motivação inicial a partir da observação de desafios enfrentados em uma empresa do setor corporativo, onde a gestão e o acesso às informações institucionais ainda apresentam dificuldades significativas. Nesse cenário, verificou-se que grande parte dos documentos internos se encontra armazenada em ambientes digitais pouco intuitivos e de difícil navegação.

Frequentemente, quando um colaborador precisa localizar uma informação ou um documento específico, ele depende do auxílio de outro profissional que já conhece os caminhos e locais corretos para encontrar o material desejado. Esse processo gera uma série de dificuldades, como a necessidade de interromper a rotina de outro colaborador, que muitas vezes precisa se deslocar fisicamente até a estação de trabalho do solicitante e a consequente perda de tempo e produtividade associada à busca manual por informações.

Como forma de solucionar essa problemática, propõe-se o desenvolvimento de um sistema baseado em Inteligência Artificial, utilizando um modelo de linguagem natural, que funcione de maneira semelhante ao ChatGPT, Deepseek e outros. O projeto consiste na criação de um assistente virtual inteligente, capaz de receber, armazenar e processar documentos e arquivos institucionais (ADAMOPOULOU; MOUSSIADES, 2020) utilizando inicialmente um banco de dados para viabilizar a flexibilidade e a escalabilidade necessárias. Através da aplicação de técnicas de processamento de linguagem natural (NLP), o sistema é capaz de interpretar as informações armazenadas e responder às dúvidas dos colaboradores de forma ágil e precisa, como um *chatbot* (JURAFSKY; MARTIN, 2024).

Por exemplo, ao invés de um novo colaborador precisar gastar tempo procurando manualmente um documento ou depender de alguém que lhe mostre onde encontrar as informações sobre a estrutura organizacional, ele poderá simplesmente interagir com o sistema e obter, de maneira instantânea, as respostas desejadas.

Para potencializar a capacidade do assistente virtual e garantir respostas baseadas em dados reais armazenados pela instituição, é utilizada a abordagem de Geração Aumentada por Recuperação (RAG — Retrieval-Augmented Generation) (LEWIS et al., 2020). Esse método combina o poder dos modelos de linguagem natural com a recuperação de documentos relevantes em tempo real, permitindo que o sistema consulte dinamicamente as bases de dados e documentos institucionais antes de gerar uma resposta contextualizada e precisa. A utilização de RAG mostra-se especialmente adequada para ambientes corporativos, onde o conhecimento está distribuído em diversos documentos e sistemas internos.

Figura 2 – Fluxo de Funcionamento da arquitetura RAG



Fonte: Dubiella, 2024.

A implementação desta solução traz uma série de vantagens e benefícios para a organização. Entre eles, destaca-se a significativa redução do tempo gasto na busca por documentos e informações, a diminuição da sobrecarga de trabalho dos colaboradores mais experientes, que deixam de ser constantemente solicitados para orientar colegas, bem como a melhoria da eficiência e da produtividade no ambiente de trabalho. Além disso, o sistema proposto pode atuar como um verdadeiro acelerador para diversas tarefas que demandam o acesso rápido e preciso a informações internas da empresa, como instrumentos normativos, portarias, regulamentos ou políticas institucionais. Adicionalmente, a solução atuará na automação e padronização da geração de novos relatórios em formato PDF, utilizando motores de renderização para extrair e estruturar os dados consultados de forma oficial e instantânea.

Figura 3 – Visão geral do funcionamento do PortoGPT com RAG



Fonte: Autores, 2026.

1.1 OBJETIVOS

Desenvolver uma solução baseada em Inteligência Artificial, utilizando modelos de linguagem natural para acelerar e facilitar o acesso a informações internas da empresa, reduzindo o tempo gasto na busca de informações específicas e automatizando a geração de documentos padronizados.

1.2 OBJETIVOS ESPECÍFICOS

1. Levantar e analisar as principais dificuldades enfrentadas atualmente pelos colaboradores no acesso aos documentos internos.
2. Investigar como o uso de modelos de linguagem de grande escala (LLM) pode ser aplicado para melhorar a eficácia na análise de documentos institucionais
3. Projetar e implementar um protótipo de assistente virtual inteligente, capaz de armazenar, processar e responder dúvidas baseadas exclusivamente na base de conhecimento da empresa.
4. Desenvolver um motor de renderização utilizando templates (Jinja), visando a automação, padronização e exportação de novos relatórios organizacionais em formato PDF.
5. Testar a solução por meio de cenários simulados de uso, verificando se os principais fluxos atendem aos requisitos definidos e se contribuem para reduzir o esforço por busca de informações.
6. Propor possibilidades de adaptação e expansão para diferentes contextos organizacionais.

2 DESENVOLVIMENTO

Nesta etapa, o levantamento das necessidades do sistema foi realizado a partir da observação direta de cenários corporativos reais, de conversas informais com profissionais da área e da vivência prática de integrantes do grupo. Neste capítulo, são apresentadas as etapas utilizadas para elaboração do projeto, em cada etapa serão informadas as ferramentas utilizadas para a conclusão destes passos.

2.1 CARACTERIZAÇÃO DA PESQUISA

Esse trabalho caracteriza-se como uma pesquisa-ação aplicada ao desenvolvimento de uma solução tecnológica, pois parte da identificação de um problema observado no contexto real de trabalho e propõe uma intervenção prática para sua resolução. A problemática relacionada à dificuldade de localização, organização e reutilização de documentos institucionais foi percebida a partir da vivência direta de integrantes do grupo em ambiente corporativo, onde a busca por informações dependia frequentemente do conhecimento prévio de colaboradores mais experientes e de processos manuais pouco eficientes.

Dessa forma, o levantamento de requisitos não foi conduzido por meio de uma pesquisa formal de entrada ou saída com usuários, como questionários estruturados ou métricas corporativas antes e depois da implantação. Em vez disso, os requisitos foram definidos com base na observação direta do problema, em conversas informais com profissionais da área e na experiência prática de dois integrantes do projeto que atuaram no ambiente em que a dificuldade foi identificada. A partir desse diagnóstico, o grupo interveio no problema por meio do desenvolvimento do PortoGPT, uma solução/produto baseada em Inteligência Artificial, voltada a melhorar a recuperação de informações, a organização documental e a padronização de documentos.

2.2 MODELO DE NEGÓCIO

Visando a organização das etapas do software em questão, foi elaborado um modelo de negócios, que tem como finalidade resumir as etapas do projeto de maneira organizada, desenvolvido com a ferramenta canvas (OSTERWALDER; PIGNEUR, 2010).

2.3 ELICITAÇÃO DE REQUISITOS

Nessa etapa, o levantamento das necessidades do sistema foi realizado por meio de conversas informais com profissionais da área e observação de cenários corporativos reais, de conversas informais com profissionais da área e da vivência prática de integrantes do grupo no ambiente em que o problema foi identificado. A experiência dos autores permitiu compreender as principais dificuldades enfrentadas na busca por documentos internos, especialmente em situações nas quais o colaborador depende de outros profissionais para localizar informações dispersas em bases pouco intuitivas.

Por se tratar de uma pesquisa-ação, o foco da etapa de requisitos esteve na compreensão do problema e na definição de uma intervenção prática para solucioná-lo. Assim, os requisitos foram organizados com base nas dores observadas no cotidiano operacional, nas necessidades funcionais esperadas para um assistente virtual corporativo e nas boas práticas de sistemas voltados à gestão documental, recuperação de informação e controle de acesso.

2.3.1 REQUISITOS DE USUÁRIOS

O levantamento focou nas funcionalidades essenciais que o assistente virtual deve oferecer. As informações foram coletadas com base na vivência prática no ambiente portuário, identificando as perguntas mais frequentes e as dificuldades de acesso aos dados na intranet.

2.3.2 REQUISITOS DO SISTEMA

Aqui, foram elencadas as funcionalidades que o assistente (PortoGPT) disponibiliza. Para a modelagem do sistema, foram elaborados diagramas representando a estrutura e o funcionamento da aplicação, com o objetivo de auxiliar na organização e visualização dos processos e componentes do projeto.


2.3.3 DIAGRAMA DE CASO DE USO

Conectado aos requisitos levantados, este diagrama projeta as interações entre os usuários (Usuário Comum, Editor e Administrador) e o sistema através da linguagem de modelagem unificada (UML) (SOMMERVILLE, 2011).

Este diagrama ilustra as fronteiras do sistema e as interações permitidas para os diferentes perfis de usuários do PortoGPT. Visando a segurança e o controle

operacional, a arquitetura de permissões foi dividida em três atores principais. O Usuário Comum atua na ponta operacional, interagindo com a Inteligência Artificial via chat, submetendo novos documentos para formatação e acompanhando o status de suas solicitações e notificações. O Editor atua com privilégios intermediários, focando estritamente na gestão operacional do acervo de PDFs ativos e inativos. Por fim, o Administrador possui privilégios sistêmicos globais, sendo o responsável por gerenciar parâmetros da IA, contas de usuários e atuar como o validador final no fluxo de submissão de novos conhecimentos à base de dados.

Figura 4 – Diagrama de Caso de Uso




Fonte: Autores, 2026.

2.3.4 DIAGRAMA DE ATIVIDADES

Nesta etapa, são traçados o fluxo lógico e os caminhos de execução dentro da plataforma. Desde o momento em que o usuário faz uma pergunta no chat até o processamento feito pelo modelo de linguagem e a devolução da resposta.

O Diagrama de Atividades do Usuário Comum mapeia as possíveis jornadas lógicas do colaborador dentro da plataforma. O fluxo demonstra a funcionalidade central de realizar perguntas no chat e obter respostas baseadas no contexto vetorial (RAG), mas avança ao detalhar o novo processo de submissão documental. Quando o usuário anexa um arquivo no chat, o sistema inicia um fluxo de aprovação, processando uma prévia do documento, registrando-o com o status "pendente" e disparando notificações ao painel administrativo. O diagrama também ilustra a jornada de acompanhamento pós-envio, na qual o usuário consulta suas notificações para confirmar a aprovação do material ou, em caso de reprovação, recebe o *feedback* do administrador com a permissão de corrigir e reenviar o arquivo uma única vez.


Figura 5 – Diagrama de Atividades (Usuário Comum)



Fonte: Autores, 2026.

O Diagrama de Atividades do Administrador detalha o fluxo de governança e controle de qualidade documental do sistema. O destaque deste fluxo é a implementação do processo de validação, no qual o perfil administrador atua como um filtro indispensável para garantir a confiabilidade da base de conhecimento da Inteligência Artificial. Ao receber notificações no sistema sobre novos documentos pendentes, o administrador analisa o arquivo bruto enviado e a prévia processada. A partir desta etapa, é tomada a decisão de reprovar a solicitação — enviando uma justificativa de adequação ao usuário — ou aprovar o documento. Apenas após a aprovação explícita, o sistema copia o arquivo para a base ativa, aciona a vetorização do conteúdo e o torna disponível para ser consultado pela IA e pelos demais colaboradores.

Figura 6 – Diagrama de Atividades (Administrador)



Fonte: Autores, 2026.

2.3.5 DIAGRAMA DE BANCO DE DADOS

Para o armazenamento e recuperação rápida dos documentos, o projeto utiliza um modelo de banco de dados vetorial, essencial para aplicações de IA (ChromaDB), e um banco de dados relacional para usuários. A estrutura focará na separação de metadados e fragmentos de texto (embeddings).


Para o armazenamento e recuperação rápida dos documentos, o projeto utiliza uma abordagem híbrida de banco de dados. O sistema utiliza dois mecanismos principais para garantir a flexibilidade e escalabilidade do assistente virtual:

1. SQLite (backend/portogpt.db): Banco de dados relacional responsável por armazenar os dados estruturados da aplicação. Sua estrutura divide-se nas seguintes tabelas principais:
 - users: Armazena os usuários (id, email, password_hash, name, role, status, last_login).
 - chat_sessions: Representa a sessão de uma conversa individual (id, user_id, title, created_at, updated_at).
 - chat_history: Registra cada interação da conversa (id, user_id, session_id, message, response, created_at).
 - documents: Controla os PDFs (id, filename, original_name, title, description, active, uploaded_by, etc).
 - templates: Gerencia os modelos administrativos (id, filename, title, description, active, uploaded_by).
 - ai_settings: Armazena os parâmetros configuráveis da IA em formato JSON (key, value).
2. ChromaDB (backend/chroma_db): Banco de dados vetorial essencial para aplicações de IA, responsável pela busca semântica nos documentos PDF ativos. A estrutura foca na separação de metadados e fragmentos de texto (embeddings).

O Modelo Entidade-Relacionamento (MER) descreve a estrutura do banco de dados em termos de entidades, atributos e relacionamentos utilizados no assistente virtual. O banco de dados foi projetado utilizando uma abordagem híbrida, onde o

modelo relacional é responsável pelo controle de acesso (usuários), controle de sessões e armazenamento do histórico do chat. Adicionalmente, a estrutura relacional foi expandida para suportar o fluxo de governança de documentos, incluindo o controle rigoroso de status de aprovação, o registro temporal de eventos (*document_events*) para fins de auditoria, e o rastreamento de notificações lidas. Paralelamente, os arquivos institucionais e seus vetores semânticos (*embeddings*) são geridos de forma assíncrona por um banco de dados vetorial (ChromaDB). Essa organização foi estruturada com a intenção de garantir segurança na autenticação, governança da informação, além de alta performance e precisão na recuperação dos dados pela Inteligência Artificial.

Figura 7 - Diagrama de Banco de Dados




Fonte: Autores, 2026.

2.4 PROTOTIPAÇÃO

Para a prototipação inicial da interface, foi desenvolvido um modelo visual da tela principal do sistema, com o objetivo de representar a aparência e a experiência de uso do chat antes da implementação completa da aplicação. Essa etapa auxiliou na definição da organização dos elementos visuais, navegação e estrutura da interface, servindo como base para o desenvolvimento do frontend do projeto.

Figura 8 – Tela de Protótipo

PortoGpt 1.0



Fonte: Autores, 2026.

2.5 VALIDAÇÃO DE REQUISITOS

Para a validação, algumas funcionalidades principais do software foram submetidas a testes práticos. Foram definidos cenários simulados de uso (ex: buscar uma norma específica) para validar se a resposta gerada pela inteligência artificial é precisa e se o sistema atende às necessidades dos colaboradores.

2.6 IMPLEMENTAÇÃO E HOMOLOGAÇÃO

Para homologar a solução, foram realizados testes funcionais em cenários simulados de uso, como a busca por normas específicas, envio de documentos PDF, aprovação administrativa, reindexação da base e consulta ao histórico de conversas.

Esses testes tiveram como objetivo verificar se os principais fluxos atendiam aos requisitos definidos e se o sistema respondia de forma coerente com os documentos cadastrados, analisando a velocidade das respostas, a ausência de "alucinações" (respostas inventadas pela IA) e a facilidade no uso da interface.

2.7 DESENVOLVIMENTO DE SOFTWARE

O sistema foi projetado utilizando tecnologias modernas de inteligência artificial e desenvolvimento web.

2.7.1 FERRAMENTAS DE APOIO AO DESENVOLVIMENTO

Para apoiar o desenvolvimento do PortoGPT, foram utilizadas ferramentas voltadas à codificação, versionamento, documentação técnica e apoio à pesquisa. O Visual Studio Code foi adotado como ambiente principal de desenvolvimento, permitindo a edição dos arquivos do frontend e do backend, organização do projeto e execução local da aplicação. O GitHub foi utilizado como repositório de código-fonte, contribuindo para o controle de versões, registro das alterações realizadas e organização colaborativa do desenvolvimento.

No backend, a documentação e a validação das rotas da API foram apoiadas pelo Swagger, disponibilizado automaticamente pelo FastAPI. Essa ferramenta permitiu visualizar os endpoints implementados, testar requisições e compreender a estrutura de comunicação entre frontend e backend.

Além disso, foram utilizados agentes e plataformas de Inteligência Artificial como apoio em consultas técnicas, revisão de conceitos, pesquisa geral e auxílio na organização de ideias durante o desenvolvimento, sempre mantendo a responsabilidade dos autores sobre a análise, adaptação e aplicação das informações no contexto do projeto.

2.7.2 DESENVOLVIMENTO FRONT-END

A interface de usuário foi concebida para ser limpa e direta, assemelhando-se a plataformas de chat conversacional. Foram utilizadas tecnologias web React, CSS3, JavaScript e Vite, garantindo responsividade, e lucide-react para ícones e interface. O front-end atua de forma inteligente e dinâmica, possuindo recursos como o Carrossel da Tela Inicial, que não tem função apenas estética, mas atua sugerindo *prompts* de forma autônoma.

O front-end consulta a API do sistema para identificar PDFs ativos e o histórico recente do usuário. Com isso, os cartões do carrossel são moldados dinamicamente: se um novo documento foi inserido na base, o cartão adapta-se para sugerir um resumo dos pontos críticos desse novo arquivo; e com base no histórico do usuário na semana, o sistema reaproveita os assuntos mais frequentes. Ao interagir com o cartão, o texto é automaticamente enviado ao chat, reduzindo o atrito inicial e tornando a ferramenta um assistente proativo de produtividade. Além disso, o motor de templates Jinja foi integrado para viabilizar a geração dinâmica de documentos PDF padronizados (RONACHER, 2008).

2.7.3 DESENVOLVIMENTO BACK-END

O núcleo do sistema foi desenvolvido em Python, dada a sua vasta compatibilidade com bibliotecas de Inteligência Artificial, utilizando o framework FastAPI para a criação de rotas rápidas e eficientes (PYTHON SOFTWARE FOUNDATION, 2023; RAMÍREZ, 2018). A arquitetura de software implementada abrange o gerenciamento inteligente de usuários, o histórico de interações e a orquestração do fluxo da IA.

O acesso administrativo e a segurança do sistema baseiam-se em perfis de usuário (*roles*). A senha nunca é armazenada em texto puro, sendo transformada em hash por PBKDF2 (NIST, 2010), e usuários inativos têm a autenticação bloqueada diretamente no back-end.

Para o histórico de conversas, a estrutura atua em duas camadas: sessões e mensagens. O chat só passa a existir no banco quando a primeira mensagem é enviada, momento em que o back-end gera um título dinâmico focado no assunto e salva a interação.

No que tange ao processamento de linguagem natural (NLP), a orquestração foi feita com a biblioteca LlamaIndex, conectando-se ao modelo LLaMA 3 (LLAMAINDEX, 2023; META AI, 2024). O modelo de linguagem é acessado por meio da API Groq, enquanto os embeddings são gerados com o modelo da Hugging Face e armazenados no ChromaDB (HUGGING FACE, 2023; CHROMADB, 2023). Para melhorar a seleção dos trechos recuperados, o sistema também aplica uma etapa de reranking com modelo cross-encoder *cross-encoder/ms-marco-MiniLM-L-12-v2*, priorizando os fragmentos mais relevantes antes da geração da resposta. O script de indexação lê apenas os PDFs ativos, extrai o conteúdo e gera os embeddings. Se

um documento for desativado, o índice é recriado para garantir que a IA não sofra "alucinações" utilizando conteúdos defasados. Para lidar com inconsistências — como o back-end manter em memória uma coleção antiga após a recriação da base — foi desenvolvida uma rotina de correção autônoma que reindexa a base ativa e recarrega o motor de chat, evitando falhas na comunicação com o usuário.

2.8 REQUISITOS

Com base nos dados coletados e na arquitetura definida para a análise de documentos corporativos, esta seção detalha os requisitos do sistema. A plataforma foi idealizada para atender não apenas às necessidades explícitas levantadas, mas também para integrar funcionalidades padrão de mercado e diferenciais de usabilidade.

Abaixo, constam os requisitos funcionais, não funcionais e de negócios, separados pelo perfil de acesso do usuário. A última coluna das tabelas categoriza cada requisito quanto à sua origem e natureza, utilizando a seguinte legenda:

1 - Requisito identificado no levantamento inicial: corresponde às necessidades percebidas por meio da observação direta, vivência prática dos autores, conversas informais com profissionais da área e análise dos cenários de uso.

2 - Requisito derivado por análise técnica: corresponde às funcionalidades identificadas a partir da análise do problema, comparação com soluções semelhantes, boas práticas de sistemas corporativos e necessidades percebidas durante o desenvolvimento do protótipo.

3 - Requisito comum em sistemas profissionais: corresponde às funcionalidades não mencionadas diretamente no levantamento inicial, mas esperadas em aplicações web profissionais, como login, histórico, controle de perfil, responsividade e encerramento de sessão.

Tabela 1 – Requisitos Funcionais do Sistema

Esta seção foca na interatividade e na recuperação de informação pelo usuário colaborador comum da empresa

[RF01] O sistema deve permitir que o usuário faça perguntas em linguagem natural por meio de um chat.	1
[RF02] O sistema deve permitir que o usuário visualize os PDFs aprovados e disponíveis na base documental.	1

[RF03] O sistema deve processar a pergunta e retornar uma resposta baseada nos documentos indexados e ativos na base.	1
[RF04] O sistema deve permitir que a IA mencione, quando possível, o documento ou trecho utilizado como apoio para a resposta.	2
[RF05] O sistema deve permitir que o usuário comum envie documentos PDF pelo chat, ficando pendentes de aprovação administrativa antes de entrarem na base oficial, para alimentar o banco de conhecimento e a base de documentos.	2
[RF06] O sistema deve permitir o login do usuário por meio dos dados previamente cadastrados: e-mail e senha.	3
[RF07] O sistema deve gerenciar o histórico de conversas com cada usuário, disponibilizando-o para consultas futuras e possível exclusão do mesmo.	3
[RF08] O sistema deve permitir a visualização de informações úteis do sistema do usuário, como data de criação, último acesso e função.	3
[RF09] O sistema deve permitir o logout do usuário, encerrando sua sessão.	3

Fonte: Autores, 2026.

Tabela 2 – Requisitos Funcionais do Sistema (Administrador)

Esta seção foca na manutenibilidade e gerenciamento de dados concedidos ao administrador do sistema

[RF11] O sistema deve permitir que o administrador faça o upload <i>definitivo</i> de novos documentos PDF para alimentar o banco de conhecimento e a base de documentos.	1
[RF12] O sistema deve permitir que o administrador aprove ou reprove documentos enviados por usuários, registrando feedback em caso de reprovação e notificando o usuário.	1
[RF13] O sistema deve permitir que o administrador exclua ou atualize documentos defasados da base de dados vetorial.	1
[RF14] O sistema deve processar os novos arquivos em background, dividindo-os em fragmentos (chunks) e salvando-os no ChromaDB.	2
[RF15] O sistema deve permitir que o administrador ajuste o comportamento do PortoGPT, com parâmetros predefinidos de resposta que entram como prompt do assistente.	2
[RF16] O sistema deve permitir que o administrador cadastre templates da empresa para uso em futura formatação de documentos.	2
[RF17] O sistema deve permitir que o administrador gerencie os usuários do sistema e suas permissões (inclusão, exclusão, atribuir função).	3

Fonte: Autores, 2026.

Tabela 3 – Requisitos Não Funcionais do Sistema (Geral)

Esta seção define a eficiência de desempenho e arquitetura.

[RNF01] O tempo de resposta do modelo de IA no chat não deve exceder 10 segundos em conexões estáveis.	1
[RNF02] O sistema deve ser desenvolvido em Python utilizando o framework FastAPI para garantir alto desempenho.	1
[RNF03] Arquitetura frontend composta por React para renderização declarativa e Vite para empacotamento e dev server dinâmicos.	1
[RNF04] O sistema deve permitir a alternância da interface entre modo claro e modo escuro.	2
[RNF05] O sistema deve ter uma interface responsiva, adaptando-se a desktops e dispositivos móveis.	3

Fonte: Autores, 2026.

Tabela 4 – Requisitos de Negócios do Sistema

Esta seção justifica o Retorno sobre Investimento (ROI) e a mitigação de riscos.

[RN01] O sistema deve reduzir o tempo gasto na busca manual de documentos institucionais.	1
[RN02] O sistema deve garantir que apenas documentos vigentes e aprovados alimentem a base de conhecimento.	1
[RN03] O sistema deve mitigar riscos jurídicos evitando a geração de informações falsas (alucinações).	2
[RN04] O sistema deve assegurar que todos os relatórios gerados sigam a identidade visual e normas da instituição.	2

Fonte: Autores, 2026.

A seguir, são apresentados os casos de uso estendidos do sistema PortoGPT, responsáveis por detalhar o comportamento das principais funcionalidades da aplicação. Os casos de uso descrevem as interações entre os atores e o sistema, permitindo uma melhor compreensão dos processos, validações e fluxos operacionais previstos na solução proposta.

Quadro 1 – Caso de Uso Estendido: Fazer Login

Caso de Uso: Fazer Login
Descrição: Permite que o usuário acesse o sistema PortoGPT por meio de credenciais cadastradas.
Atores: Usuário comum, Editor e Administrador.
Pré-condições:

O usuário deve possuir e-mail e senha cadastrados no sistema. A conta deve estar ativa.
Pós-condições: O usuário é autenticado e direcionado para a tela inicial do sistema, com acesso às funcionalidades permitidas conforme seu perfil.
Fluxo Principal: 1. O usuário acessa a tela de login. 2. O sistema exibe os campos de e-mail e senha. 3. O usuário informa suas credenciais. 4. O usuário seleciona o botão “Entrar”. 5. O sistema valida os dados informados. 6. O sistema identifica o perfil do usuário. 7. O sistema libera o acesso à aplicação.
Fluxo Alternativo: 1.1 Caso o e-mail ou senha estejam incorretos, o sistema exibe uma mensagem de erro. 1.2 Caso a conta esteja inativa, o sistema bloqueia o acesso. 1.3 Caso ocorra falha de comunicação com o servidor, o sistema informa que não foi possível realizar o login.

Fonte: Autores, 2026.

Quadro 2 – Caso de Uso Estendido - Interagir com o Assistente (Chat)

Caso de Uso: Interagir com o Assistente
Descrição: Permite que o usuário realize perguntas em linguagem natural para a inteligência artificial, recebendo respostas baseadas nos documentos cadastrados na base do sistema.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado. A base documental deve possuir documentos ativos e indexados.
Pós-condições: O sistema exibe uma resposta ao usuário e registra a interação no histórico da conversa.
Fluxo Principal: 1. O usuário acessa a tela inicial do chat. 2. O usuário digita uma pergunta no campo de mensagem. 3. O sistema envia a pergunta para a API. 4. O backend consulta a base vetorial de documentos. 5. A inteligência artificial processa o contexto encontrado. 6. O sistema retorna a resposta ao usuário. 7. A conversa é registrada no histórico.
Fluxo Alternativo: 1.1 Caso a pergunta seja vaga, o sistema pode solicitar mais detalhes ao usuário.

- 1.2 Caso a informação não exista na base documental, o sistema informa que não encontrou dados suficientes.
- 1.3 Caso ocorra erro na comunicação com a IA, o sistema exibe uma mensagem de falha.

Fonte: Autores, 2026.

Quadro 3 – Caso de Uso Estendido: Utilizar Sugestões do Carrossel

Caso de Uso: Utilizar Sugestões do Carrossel
Descrição: Permite que o usuário inicie uma conversa a partir de sugestões automáticas exibidas na tela inicial do chat.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado. O sistema deve carregar as sugestões com base nos documentos disponíveis e no histórico recente.
Pós-condições: Uma pergunta sugerida é enviada automaticamente ao chat e a resposta da IA é exibida.
Fluxo Principal: 1. O usuário acessa a tela inicial do chat. 2. O sistema exibe cartões com sugestões de perguntas. 3. O usuário seleciona uma sugestão. 4. O frontend envia a pergunta correspondente para a API. 5. A IA processa a solicitação com base nos documentos. 6. O sistema exibe a resposta no chat. 7. A interação é salva no histórico.
Fluxo Alternativo: 1.1 Caso não existam documentos ativos, o sistema exibe sugestões genéricas. 1.2 Caso não exista histórico suficiente, o sistema apresenta perguntas iniciais padrão. 1.3 Caso ocorra erro no carregamento das sugestões, o usuário ainda poderá digitar a pergunta manualmente.

Fonte: Autores, 2026.

Quadro 4 – Caso de Uso Estendido: Visualizar Histórico de Chats

Caso de Uso: Visualizar Histórico de Chats
Descrição: Permite que o usuário acesse conversas realizadas anteriormente e continue uma interação já iniciada.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado e possuir conversas salvas.

Pós-condições: O sistema carrega as mensagens da conversa selecionada.
Fluxo Principal: 1. O usuário acessa o sistema. 2. O sistema exibe a barra lateral com o histórico de chats. 3. O usuário visualiza a lista de conversas salvas. 4. O usuário seleciona uma conversa. 5. O sistema recupera as mensagens da sessão. 6. O chat é carregado com o conteúdo anterior.
Fluxo Alternativo: 1.1 Caso não existam conversas salvas, o sistema exibe mensagem informando ausência de histórico. 1.2 Caso a conversa não seja encontrada, o sistema informa que não foi possível carregá-la. 1.3 O usuário pode iniciar uma nova conversa por meio do botão “Novo chat”.

Fonte: Autores, 2026.

Quadro 5 – Caso de Uso Estendido: Buscar Chats

Caso de Uso: Buscar Chats
Descrição: Permite que o usuário localize conversas anteriores por meio de palavras-chave.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado e possuir conversas registradas.
Pós-condições: O sistema exibe apenas as conversas compatíveis com o termo pesquisado.
Fluxo Principal: 1. O usuário acessa a barra lateral. 2. O usuário digita uma palavra-chave no campo de busca. 3. O sistema filtra as conversas salvas. 4. O sistema exibe os resultados encontrados. 5. O usuário seleciona a conversa desejada.
Fluxo Alternativo: 1.1 Caso nenhuma conversa corresponda à busca, o sistema exibe mensagem de ausência de resultados. 1.2 O usuário pode limpar o campo de busca para visualizar novamente todo o histórico.

Fonte: Autores, 2026.

Quadro 6 – Caso de Uso Estendido: Excluir Chat

Caso de Uso: Excluir Chat

Descrição: Permite que o usuário remova uma conversa salva em seu histórico.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado e possuir conversas salvas.
Pós-condições: A conversa selecionada é removida do histórico do usuário.
Fluxo Principal: 1. O usuário acessa o histórico de chats. 2. O sistema exibe a lista de conversas salvas. 3. O usuário seleciona a opção de excluir uma conversa. 4. O sistema solicita confirmação. 5. O usuário confirma a exclusão. 6. O sistema remove a conversa do histórico. 7. A lista de chats é atualizada.
Fluxo Alternativo: 1.1 Caso o usuário cancele a confirmação, a conversa permanece salva. 1.2 Caso ocorra erro na exclusão, o sistema mantém o histórico e exibe uma mensagem de erro.

Fonte: Autores, 2026.

Quadro 7 – Caso de Uso Estendido: Enviar PDF pelo Chat

Caso de Uso: Enviar PDF pelo Chat.
Descrição: Permite que o usuário envie um arquivo PDF durante uma conversa com a inteligência artificial
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado. O arquivo deve estar em formato PDF.
Pós-condições: O documento é salvo no sistema. Para usuários comuns, o arquivo fica pendente de aprovação. Para administradores e editores, o documento pode ser aprovado automaticamente.
Fluxo Principal: 1. O usuário acessa o chat. 2. O usuário seleciona a opção de anexar arquivo. 3. O usuário escolhe um PDF. 4. O usuário pode escrever uma mensagem relacionada ao arquivo. 5. O sistema envia o PDF para o backend. 6. O backend salva o arquivo. 7. O sistema processa o documento. 8. O sistema registra a solicitação. 9. O sistema exibe uma resposta confirmando o envio.

Fluxo Alternativo:

- 1.1 Caso o arquivo não seja PDF, o sistema deve impedir ou informar erro no envio.
- 1.2 Caso o usuário comum envie o documento, ele ficará pendente de aprovação.
- 1.3 Caso o administrador ou editor envie o documento, ele poderá ser publicado diretamente na base.
- 1.4 Caso ocorra erro no upload, o sistema informa que não foi possível enviar o arquivo.

Fonte: Autores, 2026.

Quadro 8 – Caso de Uso Estendido: Visualizar PDFs Disponíveis

Caso de Uso: Visualizar PDFs Disponíveis
Descrição: Permite que o usuário comum visualize os documentos aprovados e disponíveis na base documental do PortoGPT.
Atores: Usuário comum.
Pré-condições: O usuário deve estar autenticado. Devem existir documentos aprovados na base.
Pós-condições: O sistema exibe os PDFs disponíveis para consulta.
Fluxo Principal: 1. O usuário acessa a opção “PDFs disponíveis”. 2. O sistema consulta a base de documentos. 3. O sistema exibe os PDFs aprovados em formato de cards. 4. O usuário visualiza título, descrição, tamanho e data de atualização. 5. O usuário pode abrir o PDF em nova aba.
Fluxo Alternativo: 1.1 Caso não existam PDFs aprovados, o sistema exibe mensagem informativa. 1.2 Caso ocorra erro no carregamento, o sistema exibe mensagem de falha. 1.3 O usuário pode usar o campo de busca para localizar documentos específicos.

Fonte: Autores, 2026.

Quadro 9 – Caso de Uso Estendido: Acompanhar Minhas Solicitações

Caso de Uso: Acompanhar Minhas Solicitações
Descrição: Permite que o usuário acompanhe o status dos documentos enviados para aprovação.
Atores: Usuário comum.
Pré-condições: O usuário deve estar autenticado e ter enviado ao menos um documento.
Pós-condições: O sistema exibe as solicitações do usuário com seus respectivos status.

Fluxo Principal:

1. O usuário acessa a tela “Minhas solicitações”.
2. O sistema busca os documentos enviados pelo usuário.
3. O sistema exibe cada solicitação com status, data e informações do arquivo.
4. O usuário pode abrir o arquivo original.
5. O usuário pode abrir o arquivo processado.
6. O usuário pode visualizar o histórico da solicitação.

Fluxo Alternativo:

- 1.1 Caso não existam solicitações, o sistema exibe mensagem informativa.
- 1.2 Caso a solicitação tenha sido reprovada, o sistema exibe o feedback do administrador.
- 1.3 Caso a solicitação esteja aprovada, o documento passa a integrar a base disponível.

Fonte: Autores, 2026.

Quadro 10 – Caso de Uso Estendido: Reenviar Solicitação Reprovada

Caso de Uso: Reenviar Solicitação Reprovada
Descrição: Permite que o usuário envie novamente um documento que foi reprovado pelo administrador.
Atores: Usuário comum.
Pré-condições: O usuário deve estar autenticado, possuir uma solicitação reprovada e ainda não ter realizado o reenvio permitido pelo sistema.
Pós-condições: O documento reenviado retorna ao status pendente para nova análise administrativa.
Fluxo Principal: 1. O usuário acessa “Minhas solicitações”. 2. O sistema exibe as solicitações reprovadas. 3. O usuário visualiza o feedback informado pelo administrador. 4. O usuário seleciona a opção “Reenviar”. 5. O usuário escolhe um novo arquivo PDF. 6. O sistema substitui o arquivo anterior. 7. O status da solicitação volta para pendente. 8. O administrador passa a visualizar a solicitação novamente.
Fluxo Alternativo: 1.1 Caso o usuário já tenha reenviado uma vez, o sistema não permite novo reenvio. 1.2 Caso o arquivo seja inválido, o sistema exibe mensagem de erro. 1.3 Caso ocorra falha no envio, o status da solicitação permanece inalterado.

Fonte: Autores, 2026.

Quadro 11 – Caso de Uso Estendido: Visualizar Notificações

Caso de Uso: Visualizar Notificações
Descrição: Permite que o usuário acompanhe atualizações relacionadas a documentos, aprovações, reprovações e solicitações pendentes.
Atores: Usuário comum e Administrador.
Pré-condições: O usuário deve estar autenticado.
Pós-condições: O sistema exibe as notificações disponíveis para o usuário.
Fluxo Principal: 1. O usuário acessa o ícone de notificações. 2. O sistema consulta as notificações relacionadas ao perfil autenticado. 3. O sistema exibe as notificações mais recentes. 4. O usuário pode selecionar “Ver todas”. 5. O sistema direciona para a tela “Minhas notificações”. 6. O usuário visualiza a lista completa de notificações.
Fluxo Alternativo: 1.1 Caso não existam notificações, o sistema exibe mensagem informativa. 1.2 O usuário pode limpar notificações já visualizadas. 1.3 O administrador pode ser direcionado para solicitações pendentes ao selecionar uma notificação.

Fonte: Autores, 2026.

Quadro 12 – Caso de Uso Estendido: Gerenciar PDFs

Caso de Uso: Gerenciar PDFs
Descrição: Permite que administradores e editores cadastrem, editem, ativem, desativem e removam documentos PDF da base do sistema.
Atores: Administrador e Editor.
Pré-condições: O usuário deve estar autenticado com perfil de administrador ou editor.
Pós-condições: A base documental é atualizada conforme a ação realizada.
Fluxo Principal: 1. O usuário acessa a tela “Gerenciamento de PDFs”. 2. O sistema exibe os documentos cadastrados. 3. O usuário pode enviar um novo PDF. 4. O usuário pode editar título e descrição. 5. O usuário pode ativar ou desativar o documento. 6. O usuário pode abrir o PDF em nova aba. 7. O usuário pode visualizar o histórico do documento.

8. O usuário pode excluir um documento.

Fluxo Alternativo:

- 1.1 Caso o arquivo enviado não seja válido, o sistema exibe erro.
- 1.2 Caso o usuário não tenha permissão, o sistema bloqueia o acesso.
- 1.3 Caso o documento seja desativado, ele deixa de ser considerado pela IA.
- 1.4 Apenas o administrador pode reindexar a base.

Fonte: Autores, 2026.

Quadro 13 – Caso de Uso Estendido: Reindexar Base Vetorial

Caso de Uso: Reindexar Base Vetorial
Descrição: Permite que o administrador atualize a base vetorial utilizada pela inteligência artificial, considerando apenas documentos ativos.
Atores: Administrador.
Pré-condições: O administrador deve estar autenticado. Devem existir documentos cadastrados na base.
Pós-condições: O ChromaDB é atualizado com os documentos ativos.
Fluxo Principal: 1. O administrador acessa “Gerenciamento de PDFs”. 2. O sistema exibe a lista de documentos. 3. O administrador seleciona a opção de reindexar um PDF ou toda a base. 4. O sistema inicia o processo de reindexação. 5. O conteúdo dos PDFs ativos é processado. 6. Os embeddings são atualizados no ChromaDB. 7. O sistema informa que a reindexação foi agendada ou concluída.
Fluxo Alternativo: 1.1 Caso não existam documentos ativos, o sistema não gera novos vetores. 1.2 Caso ocorra falha no processamento, o sistema exibe mensagem de erro. 1.3 Caso um documento esteja inativo, ele não será utilizado pela IA.

Fonte: Autores, 2026.

Quadro 14 – Caso de Uso Estendido: Aprovar ou Reprovar Solicitação

Caso de Uso: Aprovar ou Reprovar Solicitação
Descrição: Permite que o administrador analise documentos enviados por usuários comuns e decida se eles serão publicados na base oficial.
Atores: Administrador.
Pré-condições:

O administrador deve estar autenticado. Deve existir ao menos uma solicitação pendente.
Pós-condições: A solicitação é aprovada ou reprovada. Em caso de aprovação, o documento passa a integrar a base documental. Em caso de reprovação, o usuário recebe feedback.
Fluxo Principal: 1. O administrador acessa “Solicitações de documentos”. 2. O sistema exibe as solicitações cadastradas. 3. O administrador visualiza o documento original. 4. O administrador visualiza o documento processado. 5. O administrador analisa a solicitação. 6. O administrador seleciona “Aprovar” ou “Reprovar”. 7. O sistema atualiza o status do documento. 8. O sistema registra o evento no histórico. 9. O sistema gera notificação para o usuário.
Fluxo Alternativo: 1.1 Caso o administrador aprove, o documento é publicado na base de PDFs. 1.2 Caso o administrador reprove, o sistema solicita o motivo da reprovação. 1.3 Caso ocorra erro na atualização, o status anterior é mantido.

Fonte: Autores, 2026.

Quadro 15 – Caso de Uso Estendido: Gerenciar Usuários

Caso de Uso: Gerenciar Usuários
Descrição: Permite que o administrador cadastre, edite, filtre e exclua usuários do sistema.
Atores: Administrador.
Pré-condições: O administrador deve estar autenticado.
Pós-condições: Os dados dos usuários são atualizados no banco de dados.
Fluxo Principal: 1. O administrador acessa a tela “Usuários”. 2. O sistema exibe a lista de usuários cadastrados. 3. O administrador pode pesquisar usuários. 4. O administrador pode filtrar por função ou status. 5. O administrador seleciona “Novo usuário” ou edita um usuário existente. 6. O administrador informa nome, e-mail, senha, função e status. 7. O sistema salva as informações. 8. A lista de usuários é atualizada.
Fluxo Alternativo: 1.1 Caso o e-mail já exista, o sistema exibe mensagem de erro. 1.2 Caso a senha não atenda ao mínimo exigido, o sistema solicita correção. 1.3 Caso o administrador tente excluir a própria conta, o sistema bloqueia a ação.

Fonte: Autores, 2026.

Quadro 16 – Caso de Uso Estendido: Configurar Parâmetros da IA

Caso de Uso: Configurar Parâmetros da IA
Descrição: Permite que o administrador ajuste o comportamento da inteligência artificial nas respostas geradas pelo PortoGPT.
Atores: Administrador.
Pré-condições: O administrador deve estar autenticado.
Pós-condições: Os parâmetros da IA são atualizados e passam a orientar as próximas respostas.
Fluxo Principal: 1. O administrador acessa “Conhecimento da IA”. 2. O sistema exibe os parâmetros configuráveis. 3. O administrador altera opções como uso exclusivo dos documentos, pedido de esclarecimento, indicação de fonte e tom da resposta. 4. O administrador pode alterar a quantidade de trechos consultados por pergunta. 5. O administrador pode inserir instruções personalizadas. 6. O administrador seleciona “Salvar parâmetros”. 7. O sistema grava os valores no banco de dados. 8. As novas configurações passam a ser usadas pela IA.
Fluxo Alternativo: 1.1 Caso ocorra erro ao salvar, o sistema exibe mensagem de falha. 1.2 Caso o administrador não altere nenhum campo, os parâmetros atuais são mantidos. 1.3 Caso valores inválidos sejam informados, o sistema solicita correção.

Fonte: Autores, 2026.

Quadro 17 – Caso de Uso Estendido: Gerenciar Templates

Caso de Uso: Gerenciar Templates
Descrição: Permite que o administrador cadastre, edite, ative, desative e remova templates utilizados como modelos de documentos.
Atores: Administrador.
Pré-condições: O administrador deve estar autenticado.
Pós-condições: A base de templates é atualizada.
Fluxo Principal: 1. O administrador acessa a tela “Templates”. 2. O sistema exibe os templates cadastrados.

3. O administrador pode buscar templates.
4. O administrador seleciona “Enviar template”.
5. O administrador escolhe um arquivo.
6. O administrador informa título e descrição.
7. O sistema salva o template.
8. O administrador pode editar, ativar, desativar ou excluir templates existentes.

Fluxo Alternativo:

- 1.1 Caso o arquivo seja inválido, o sistema exibe mensagem de erro.
- 1.2 Caso não existam templates, o sistema exibe mensagem informativa.

Fonte: Autores, 2026.

Quadro 18 – Caso de Uso Estendido: Gerar Documento por Template

Caso de Uso: Gerar Documento por Template
Descrição: Permite que o usuário gere um documento padronizado a partir de um template previamente cadastrado no sistema.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado. Deve existir ao menos um template ativo cadastrado pelo administrador.
Pós-condições: O sistema gera um documento em PDF com base nas informações fornecidas e no modelo selecionado.
Fluxo Principal: 1. O usuário acessa a funcionalidade de geração de documentos. 2. O sistema exibe os templates ativos disponíveis. 3. O usuário seleciona um template. 4. O sistema apresenta os campos necessários para preenchimento das variáveis. 5. O usuário informa os dados solicitados. 6. O backend processa o template utilizando Jinja. 7. O sistema gera o arquivo em PDF padronizado. 8. O usuário visualiza ou baixa o documento gerado.
Fluxo Alternativo: 1.1 Caso não existam templates ativos, o sistema informa que não há modelos disponíveis. 1.2 Caso algum campo obrigatório não seja preenchido, o sistema solicita a correção. 1.3 Caso ocorra falha na geração do PDF, o sistema exibe mensagem de erro e preserva os dados informados pelo usuário.

Fonte: Autores, 2026.

Quadro 19 – Caso de Uso Estendido: Visualizar Dashboard Administrativo

Caso de Uso: Visualizar Dashboard Administrativo
Descrição: Permite que o administrador acompanhe indicadores gerais da operação do sistema.
Atores: Administrador.
Pré-condições: O administrador deve estar autenticado.
Pós-condições: O sistema exibe métricas atualizadas sobre usuários, documentos, templates, conversas e atividades recentes.
Fluxo Principal: 1. O administrador acessa o módulo administrativo. 2. O sistema carrega o dashboard. 3. O sistema exibe indicadores de documentos. 4. O sistema exibe quantidade de templates. 5. O sistema exibe usuários ativos. 6. O sistema exibe conversas e mensagens registradas. 7. O sistema apresenta a saúde da base documental. 8. O sistema apresenta atividades recentes.
Fluxo Alternativo: 1.1 Caso não existam registros recentes, o sistema exibe mensagem informativa. 1.2 Caso ocorra erro no carregamento, o sistema exibe mensagem de falha. 1.3 O administrador pode atualizar os dados manualmente.

Fonte: Autores, 2026.

Quadro 20 – Caso de Uso Estendido: Visualizar Perfil

Caso de Uso: Visualizar Perfil
Descrição: Permite que o usuário visualize informações da própria conta e personalize aspectos visuais da interface.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado.
Pós-condições: O usuário visualiza seus dados e pode alterar preferências visuais.
Fluxo Principal: 1. O usuário acessa o menu de usuário. 2. O usuário seleciona “Meu perfil”. 3. O sistema exibe nome, e-mail, função, status, data de criação e último acesso. 4. O usuário visualiza as opções de personalização. 5. O usuário seleciona uma cor de destaque. 6. O sistema aplica a personalização na interface.

Fluxo Alternativo:

- 1.1 Caso os dados não sejam carregados, o sistema pode encerrar a sessão ou solicitar novo login.
- 1.2 Caso o usuário feche a tela, o sistema retorna ao ambiente anterior.

Fonte: Autores, 2026.

Quadro 21– Caso de Uso Estendido: Fazer Logout

Caso de Uso: Fazer Logout
Descrição: Permite que o usuário encerre sua sessão no PortoGPT e retorne à tela de login.
Atores: Usuário comum, Editor e Administrador.
Pré-condições: O usuário deve estar autenticado.
Pós-condições: A sessão é encerrada e o usuário precisa realizar login novamente para acessar o sistema.
Fluxo Principal: 1. O usuário acessa o menu localizado no canto superior direito da tela. 2. O sistema exibe as opções da conta. 3. O usuário seleciona a opção “Sair”. 4. O sistema remove os dados da sessão ativa. 5. O sistema redireciona o usuário para a tela de login.
Fluxo Alternativo: 1.1 Caso o usuário não selecione “Sair”, a sessão permanece ativa. 1.2 Caso ocorra erro visual no redirecionamento, o sistema mantém a conta desautenticada e exige novo login.

Fonte: Autores, 2026.

3 RESULTADO

Neste capítulo, abordaremos os protótipos de tela para o sistema, mencionando em cada um as tecnologias utilizadas, seja na visão do desenvolvedor, seja na visão do usuário final.


Conforme apresentado na Figura 9, ao acessar o sistema PortoGPT, o usuário é direcionado à Tela de Login, responsável pela autenticação e pelo controle de acesso à plataforma. Nessa etapa, é necessário informar o e-mail cadastrado e a senha vinculada à conta.

A interface também disponibiliza a opção de alternância entre tema claro e tema escuro, oferecendo maior flexibilidade visual ao usuário. Após o preenchimento

correto dos campos, o usuário deve selecionar o botão “Entrar” para que suas credenciais sejam validadas.

Do ponto de vista técnico, essa tela foi desenvolvida no frontend com React e integrada ao backend por meio da API de autenticação. Após o login, os dados do usuário autenticado são armazenados localmente para controle da sessão e direcionamento às funcionalidades permitidas conforme seu perfil de acesso.

Figura 9 – Tela de Login



Fonte: Autores, 2026.


Conforme ilustrado na Figura 10, após realizar o login, o usuário é direcionado à Tela Inicial do Chat, principal ambiente de interação com a inteligência artificial do PortoGPT.

Na região central da tela, é apresentada uma saudação personalizada com o nome do usuário autenticado. Logo abaixo, o sistema exibe sugestões de perguntas rápidas em formato de cartões interativos, que auxiliam o usuário a iniciar consultas sobre documentos recentes, prazos, exigências e procedimentos operacionais.

Na parte inferior da interface encontra-se o campo de envio de mensagens, no qual o usuário pode digitar perguntas relacionadas aos documentos disponíveis na base do sistema. A tela também permite anexar arquivos PDF, possibilitando o envio de documentos para processamento e análise.

A funcionalidade foi implementada com React no frontend, utilizando comunicação com uma API em FastAPI. Para as respostas da inteligência artificial, o sistema utiliza leitura e indexação de arquivos PDF, embeddings, banco vetorial ChromaDB, LlamaIndex e integração com modelo de linguagem via Groq, permitindo consultas em linguagem natural sobre o conteúdo documental.

Figura 10 – Tela Inicial (Chat)



Fonte: Autores, 2026.

Conforme apresentado na Figura 11, o sistema PortoGPT disponibiliza, na barra lateral, uma área de Histórico e Busca de Chats, responsável pelo armazenamento e recuperação das conversas realizadas pelo usuário.


Na parte superior da interface lateral encontra-se o botão “Novo chat”, utilizado para iniciar uma nova conversa com a inteligência artificial. Também é disponibilizado um campo de busca, permitindo localizar conversas anteriores por palavras-chave relacionadas ao conteúdo das interações.

Na seção de histórico, o sistema exibe a lista de conversas salvas, contendo o título do chat e a data ou horário da última atualização. Ao selecionar uma conversa, o usuário pode retomar a interação a partir do ponto em que ela foi interrompida. Também há opção para remover conversas do histórico.

Essa funcionalidade foi implementada com persistência em banco de dados SQLite, permitindo armazenar sessões de chat, mensagens e respostas. No

frontend, a navegação entre conversas ocorre de forma dinâmica, sem necessidade de recarregar toda a aplicação.

Figura 11 – Histórico e Busca de Chats



Fonte: Autores, 2026.

Conforme ilustrado na Figura 12, o sistema PortoGPT apresenta, no canto superior da interface, um menu vinculado ao usuário autenticado. Esse menu exibe as iniciais do usuário e, ao ser acionado, apresenta informações básicas da conta, como nome e e-mail.

Por meio desse menu, o usuário pode acessar a página “Meu perfil”, visualizar “Minhas notificações”, alternar entre modo claro e modo escuro e encerrar a sessão por meio da opção “Sair”. Ao selecionar “Sair”, o sistema remove os dados da sessão ativa e redireciona o usuário para a tela de login.

Essa funcionalidade utiliza mecanismos de controle de sessão no frontend, armazenamento local dos dados autenticados e validação de permissões no backend, garantindo que cada usuário visualize apenas as funcionalidades compatíveis com seu perfil.

Figura 12– Detalhes do Usuário




Fonte: Autores, 2026.

Conforme apresentado na Figura 13, a Tela de Perfil permite ao usuário visualizar informações detalhadas sobre sua conta no PortoGPT. A interface exibe nome, e-mail, função, status, data de criação da conta e último acesso registrado.

Além das informações cadastrais, a tela disponibiliza opções de personalização visual, permitindo alterar a cor de destaque da interface. Essa personalização contribui para uma experiência mais adaptável ao usuário final.

Do ponto de vista técnico, os dados são obtidos a partir da API de usuários e apresentados no frontend em uma interface construída com React. As preferências visuais são mantidas localmente para preservar a experiência do usuário durante o uso do sistema.

Figura 13 – Meu perfil




Fonte: Autores, 2026.

Conforme ilustrado na Figura 14, a tela “PDFs disponíveis” apresenta ao usuário comum a lista de documentos aprovados e disponíveis para consulta na base do PortoGPT.

A interface possui campo de busca para localizar documentos por título, nome do arquivo, descrição ou status. Cada documento é exibido em formato de card, contendo informações como título, descrição, tamanho do arquivo, data de atualização e botão para abertura do PDF em nova aba.

Essa tela utiliza dados fornecidos pela API de documentos, exibindo apenas os arquivos aprovados e disponíveis para consulta. Dessa forma, o usuário final consegue visualizar quais documentos fazem parte da base utilizada pela inteligência artificial.

Figura 14 – PDFs disponíveis




Fonte: Autores, 2026.

Conforme apresentado na Figura 15, a tela “Minhas solicitações” permite ao usuário acompanhar os documentos enviados para análise e aprovação.

Nessa interface, o usuário visualiza o status de cada solicitação, podendo identificar se o documento está pendente, aprovado, reprovado ou reenviado. Também é possível acessar o arquivo original, o arquivo processado, visualizar o histórico da solicitação e, em caso de reprovação, reenviar o documento uma única vez.

A tela conta com busca e filtro por data, facilitando o acompanhamento de documentos enviados. Essa funcionalidade foi implementada com persistência em banco de dados, controle de status e registro de eventos em linha do tempo.

Figura 15 – Minhas solicitações




Fonte: Autores, 2026.

Conforme ilustrado na Figura 16, a tela “Minhas notificações” concentra as atualizações relacionadas aos documentos e solicitações do usuário.

A interface apresenta notificações em ordem cronológica, informando aprovações, reprovações e eventuais feedbacks administrativos. Também há botões para retornar à tela inicial, atualizar a listagem e limpar notificações já visualizadas.

Do ponto de vista técnico, as notificações são obtidas por meio da API e armazenadas considerando o usuário autenticado. O sistema também registra notificações lidas, impedindo que avisos limpos sejam exibidos novamente após novo login.

Figura 16 – Minhas notificações




Fonte: Autores, 2026.

Conforme apresentado na Figura 17, o Dashboard Administrativo oferece ao administrador uma visão geral da operação do PortoGPT.

A tela exibe indicadores sobre documentos cadastrados, documentos aprovados, pendentes e reprovados, quantidade de templates, usuários ativos, conversas registradas e mensagens enviadas. Também apresenta uma seção de saúde da base documental e uma área de atividades recentes.

Essa tela foi desenvolvida para apoiar a gestão do sistema, reunindo dados consolidados a partir do banco SQLite e endpoints administrativos da API. O acesso é restrito a usuários com perfil de administrador.

Figura 17 – Administração



Fonte: Autores, 2026.

Conforme ilustrado na Figura 18, a tela “Usuários” permite ao administrador gerenciar os usuários cadastrados no sistema.

A interface apresenta indicadores de total de usuários ativos, inativos e pendentes. Também possui campo de busca, filtros por função e status, além da opção de cadastrar novos usuários.

Na tabela principal, são exibidos nome, e-mail, função, status, data de criação, último acesso e ações de edição ou exclusão. Essa funcionalidade foi implementada com controle de permissões, garantindo que apenas administradores possam criar, editar ou remover usuários.

Figura 18 – Usuários

Usuários
Gerencie os usuários do sistema e suas permissões.

5 Total de usuários 5 Usuários ativos 0 Usuários inativos 0 Pendentes

Q Buscar usuários... Todas as funções Todos + Novo usuário

Usuário	Função	Status	Criado em	Último acesso	Ações
V visu visu@gmail.com	Usuário	Ativo	08 de mai. de 2026	08 de mai. de 2026	
E EDITOR editor@gmail.com	Editor	Ativo	08 de mai. de 2026	08 de mai. de 2026	
N nickolas nick@portogpt.com	Administrador	Ativo	07 de mai. de 2026	08 de mai. de 2026	
GM Giovanna Melo admin@portogpt.com	Administrador	Ativo	07 de mai. de 2026	08 de mai. de 2026	
G2 giovanna 2 test@example.com	Usuário	Ativo	06 de mai. de 2026	08 de mai. de 2026	


Fonte: Autores, 2026.

Conforme apresentado na Figura 19, a tela “Conhecimento da IA” permite ao administrador configurar o comportamento da inteligência artificial e acompanhar os documentos utilizados como fonte de conhecimento.

A interface apresenta métricas sobre documentos cadastrados, documentos ativos, volume total de arquivos e quantidade de trechos consultados por pergunta. Também permite ajustar parâmetros como responder apenas com base nos documentos, informar quando não encontrar dados, solicitar esclarecimentos em perguntas vagas, mencionar documentos de apoio e definir o tom das respostas.

Essa tela está diretamente relacionada ao funcionamento da inteligência artificial, pois os parâmetros configurados são utilizados na construção das respostas. A implementação integra frontend React, API FastAPI, LlamaIndex, embeddings e banco vetorial ChromaDB.

Figura 19 – Conhecimento da IA



Fonte: Autores, 2026.


Conforme ilustrado na Figura 20, a tela “Gerenciamento de PDFs” permite que administradores e editores gerenciem os documentos utilizados pela inteligência artificial.

A interface possibilita enviar novos PDFs, editar título e descrição, ativar ou desativar documentos, abrir arquivos em nova aba, visualizar histórico, remover documentos e, no caso do administrador, reindexar a base de conhecimento.

Cada PDF é exibido em formato de card, contendo status, descrição, tamanho, data de atualização, origem do documento, usuário responsável pelo envio e, quando aplicável, o administrador responsável pela aprovação.

Essa funcionalidade utiliza armazenamento de arquivos, metadados em banco SQLite e reindexação dos documentos no banco vetorial, garantindo que apenas PDFs ativos e aprovados sejam considerados nas respostas da IA.

Figura 20 – Gerenciamento de PDFs




Fonte: Autores, 2026.

Conforme apresentado na Figura 21, a tela “Solicitações de documentos” é destinada ao administrador e permite acompanhar o fluxo de aprovação dos PDFs enviados pelos usuários.

A interface lista solicitações pendentes, aprovadas, reprovadas e reenviadas. Para cada solicitação, o administrador pode visualizar o arquivo original, o arquivo processado e o histórico completo da solicitação. Quando o documento está pendente, são exibidas as ações de aprovar ou reprovar.

Ao aprovar uma solicitação, o documento passa a integrar a base de PDFs disponíveis e pode ser utilizado pela inteligência artificial. Ao reprovar, o administrador informa um motivo, que será exibido ao usuário. Essa funcionalidade utiliza controle de status, notificações e registro de eventos em linha do tempo.

Figura 21 – Solicitações de documentos




Fonte: Autores, 2026.

Conforme ilustrado na Figura 22, a tela “Templates” permite ao administrador cadastrar e gerenciar modelos de documentos utilizados no sistema.

A interface apresenta indicadores de templates cadastrados, templates ativos e tamanho total dos arquivos. Também há campo de busca, botão para envio de novo template e ações para editar, ativar, desativar ou remover modelos existentes.

Essa funcionalidade foi planejada para apoiar fluxos futuros de padronização e formatação de documentos. Tecnicamente, os templates são armazenados no sistema de arquivos e seus metadados são registrados no banco de dados, permitindo controle e gerenciamento pela interface administrativa.

Figura 22 - Templates



Fonte: Autores, 2026.

3.1 TRABALHOS FUTUROS

Como propostas para trabalhos futuros e expansão do sistema, sugere-se a aplicação do PortoGPT em grupos maiores de usuários, contemplando diferentes setores da empresa, como administrativo, operacional, jurídico, recursos humanos e tecnologia da informação. Essa ampliação permitiria avaliar o comportamento do sistema em cenários reais de uso simultâneo, bem como identificar demandas específicas de cada área organizacional.

Também se propõe a expansão dos formatos de arquivos aceitos pela plataforma, incluindo planilhas, apresentações, documentos de texto e arquivos de áudio. No caso dos áudios, o sistema poderia incorporar recursos de transcrição automática, permitindo que reuniões, treinamentos e comunicados internos fossem convertidos em texto e posteriormente consultados pela inteligência artificial.

Outra possibilidade de evolução consiste na ampliação das funções de geração por IA, permitindo a criação automática de atas, comunicados, relatórios, resumos executivos e respostas padronizadas a partir dos documentos institucionais já aprovados na base. Além disso, recomenda-se a integração com serviços corporativos de autenticação, como Active Directory e Single Sign-On (SSO), a fim de tornar o acesso mais seguro e alinhado às práticas utilizadas em ambientes empresariais.

Por fim, sugere-se a implementação de métricas automatizadas para avaliação das respostas geradas pelo modelo de linguagem, considerando critérios como precisão, relevância, tempo de resposta e aderência às fontes consultadas. Essas métricas contribuiriam para o aprimoramento contínuo da base de conhecimento e para o aumento da confiabilidade do sistema.

4 CONCLUSÃO

O presente trabalho atingiu seu objetivo principal ao projetar e implementar um protótipo funcional do PortoGPT, um assistente virtual inteligente voltado ao apoio na recuperação de documentos institucionais em ambiente corporativo. A partir da observação direta de dificuldades enfrentadas na localização de informações internas, o projeto propôs uma intervenção prática baseada em Inteligência Artificial, organizada como uma pesquisa-ação aplicada ao desenvolvimento de produto.

Do ponto de vista técnico, a adoção da arquitetura RAG (*Retrieval-Augmented Generation*) combinada com LlamaIndex, ChromaDB, embeddings da Hugging Face, modelo de linguagem via Groq e banco relacional SQLite, permitiu estruturar um fluxo de consulta em linguagem natural sobre documentos PDF aprovados. O sistema também incorporou controle de usuários, histórico de conversas, gerenciamento de documentos, aprovação administrativa, notificações e reindexação da base, criando uma camada de governança sobre os conteúdos utilizados pela IA.

Além de otimizar a recuperação de informações, o projeto inovou ao integrar um motor de renderização (Jinja) de forma paralela ao assistente virtual. Essa funcionalidade cumpriu o objetivo específico de automatizar a criação de novos relatórios e documentos em formato PDF, mitigando a falta de padronização corporativa e acelerando rotinas operacionais por meio da injeção de variáveis inteligentes em templates predefinidos.

A interface de usuário também cumpriu seu papel ao entregar uma experiência fluida, responsiva e proativa. O uso de cartões dinâmicos no carrossel da tela inicial, que sugerem interações baseadas no histórico recente do usuário e na inserção de novos normativos, diminui a fricção de uso e consolida a ferramenta como um verdadeiro assistente de produtividade.

Embora o projeto não tenha realizado pesquisa formal de entrada e saída com usuários, os testes funcionais e cenários simulados, bem como vivência no ambiente corporativo estudado, permitiram verificar os principais fluxos previstos nos requisitos.

Por fim, conclui-se que o PortoGPT não apenas moderniza o acesso à informação, mas estabelece uma nova cultura de independência e agilidade corporativa.

5 REFERÊNCIAS

ADAMOPOULOU, Eleni; MOUSSIADES, Lefteris. Chatbots: History, technology, and applications. **Machine Learning with Applications**, v. 2, p. 100006, 2020.

Disponível em: <https://doi.org/10.1016/j.mlwa.2020.100006>. Acesso em: 10 março 2026.

CHROMADB. **Chroma: The AI-native open-source embedding database**. 2023.

Disponível em: <https://docs.trychroma.com/>. Acesso em: 10 março 2026.

DUBIELLA, Larissa. O que é RAG e como essa técnica funciona. **Alura**, 11 dez.

2024. Disponível em: <https://www.alura.com.br/artigos/o-que-e-rag>. Acesso em: 05 maio 2026.

HUGGING FACE. **Hugging Face Documentation**. 2023. Disponível em:

<https://huggingface.co/docs>. Acesso em: 10 março 2026.

JURAFSKY, Daniel; MARTIN, James H. **Speech and Language Processing: An**

Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition. 3. ed. draft. Stanford: Stanford University, 2024. Disponível em:

<https://web.stanford.edu/~jurafsky/slp3/>. Acesso em: 15 abril 2026.

LEWIS, Patrick et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. **Advances in Neural Information Processing Systems**, v. 33, p. 9459-9474,

2020. Disponível em: <https://arxiv.org/abs/2005.11401>. Acesso em: 10 março 2026.

LLAMAINDEX. **LlamaIndex Documentation**. 2023. Disponível em:

<https://docs.llamaindex.ai/>. Acesso em: 10 março 2026.

META AI. **Introducing Meta Llama 3: The most capable openly available LLM to**

date. 2024. Disponível em: <https://ai.meta.com/blog/meta-llama-3/>. Acesso em: 10 março 2026.

NEVES, Vinícios. Tipos de modelos de LLMs: generalistas, especialistas, compactos e multimodais. **Alura**, 13 jan. 2025. Disponível em:

<https://www.alura.com.br/artigos/tipos-de-llms>. Acesso em: 06 maio 2026.

NIST - National Institute of Standards and Technology. **Recommendation for Password-Based Key Derivation**: Part 1: Storage Applications. Special Publication 800-132. Gaithersburg, MD, 2010. Disponível em: <https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-132.pdf>. Acesso em: 15 abril 2026.

OSTERWALDER, Alexander; PIGNEUR, Yves. **Business Model Generation**: Inovação Em Modelos De Negócios. Rio de Janeiro: Alta Books, 2010.

PYTHON SOFTWARE FOUNDATION. **Python Language Reference (v3.12)**. 2023. Disponível em: <https://docs.python.org/3/reference/>. Acesso em: 05 fevereiro 2026.

RAMÍREZ, Sebastián. **FastAPI Documentation**. 2018. Disponível em: <https://fastapi.tiangolo.com/>. Acesso em: 05 fevereiro 2026.

RONACHER, Armin. **Jinja2 Documentation (3.1.x)**. Pallets, 2008. Disponível em: <https://jinja.palletsprojects.com/>. Acesso em: 15 abril 2026.

RUSSELL, Stuart J.; NORVIG, Peter. **Inteligência artificial**: uma abordagem moderna. 3. ed. Rio de Janeiro: Elsevier, 2013.

SOMMERVILLE, Ian. **Engenharia de software**. 9. ed. São Paulo: Pearson Prentice Hall, 2011.

ZHAO, Wayne Xin et al. A Survey of Large Language Models. **arXiv preprint arXiv:2303.18223**, 2023. Disponível em: <https://arxiv.org/abs/2303.18223>. Acesso em: 15 abril 2026.